



HACKATHON MACHINE LEARNING & DATA SCIENCE

Atlantic Haven Hotels

Prédire l'annulation d'une réservation hôtelière

Examen final — Semestre 2

Public : Master 1 — Machine Learning & Data Science
Durée : 8 heures — de 08h00 à 16h00
Modalité : distanciel complet, travail en équipe
Deadline : 16h00 précises — dernier commit
Cible à prédire : reservation_annulee
Métrique : F1-score sur la classe « annulation »
Année universitaire : 2025–2026

RABOANARY Heriniaina Andry

Données entièrement synthétiques, à usage pédagogique.

1. Contexte et organisation

À propos d'Atlantic Haven Hotels

Atlantic Haven Hotels exploite des établissements dans dix régions italiennes. Son activité couvre des destinations urbaines, culturelles, balnéaires, rurales, montagneuses et insulaires. Les réservations proviennent de plusieurs canaux et présentent des comportements très différents selon la saison, le séjour et les conditions commerciales.

Mission critique

Une annulation tardive peut laisser une chambre inoccupée et perturber la planification. Votre mission est de construire un modèle capable de prédire la cible `reservation_annulee`, **sans pénaliser inutilement les clients susceptibles de maintenir leur séjour**.

Le modèle devra fournir une **probabilité d'annulation** et une **décision binaire**. Vous devrez expliquer les compromis entre faux positifs et faux négatifs.

Organisation de la journée

Durée	8 heures — 08h00 à 16h00
Modalité	Distanciel complet
Deadline	16h00 précises — le dernier commit antérieur à la deadline fait foi

2. Description du dataset

Fichiers fournis

Fichier	Contenu
<code>reservations_train.csv</code>	Entraînement — 8 000 lignes, cible incluse
<code>reservations_test.csv</code>	Test — 2 000 lignes, sans la cible
<code>data_dictionary.csv</code>	Description détaillée des variables
<code>readme-model.md</code>	Canevas imposé du rapport

Variables principales

Groupe	Exemples	Rôle
Identifiants et dates	<code>reservation_id</code> , <code>date_reservation</code> , <code>date_arrivee</code>	Traçabilité et dimension temporelle
Destination	<code>region_hotel</code> , <code>ville</code> , <code>type_destination</code>	Contexte touristique
Séjour	<code>nuits</code> , <code>adultes</code> , <code>enfants</code> , <code>chambres</code>	Composition de la réservation
Commercial	<code>canal_reservation</code> , <code>type_acompte</code> , <code>tarif_remboursable</code>	Conditions de vente
Prix	<code>prix_moyen_nuit_eur</code> , <code>remise_pct</code> , <code>montant_total_eur</code>	Valeur économique

Groupe	Exemples	Rôle
Historique	reservations_passees, annulations_passees	Relation antérieure
Cible	reservation_annulee	0 = maintenue, 1 = annulée

Indice crucial

Les fichiers sont **ordonnés dans le temps** et le jeu de test représente des réservations **plus récentes** que celles de l'entraînement. Votre protocole de validation doit respecter cette réalité : une validation croisée aléatoire donnerait une estimation optimiste et trompeuse.

Les données sont entièrement synthétiques. Les différences régionales décrivent des contextes touristiques, saisonniers et opérationnels, et non des caractéristiques intrinsèques des populations.

3. Votre mission

Votre objectif est de construire une solution **reproductible**, de maximiser le **F1-score** sur la classe « annulation » et de démontrer que votre modèle reste pertinent sur des données plus récentes.

Étape 1 — EDA et préparation

Analysez la cible, les valeurs manquantes, les distributions, les catégories, les valeurs atypiques et les relations temporelles. Justifiez chacun des traitements appliqués.

Étape 2 — Baseline obligatoire

Construisez d'abord une **régression logistique**. Tous les prétraitements doivent être appris *uniquement* à partir des données d'entraînement.

Étape 3 — Validation et modélisation

Adoptez une validation cohérente avec l'ordre temporel. Comparez au moins **deux autres familles de modèles** et justifiez vos métriques, votre réglage et votre seuil de décision.

Étape 4 — Feature engineering

Créez des variables pertinentes à partir des dates, du séjour, du prix ou de l'historique. Évitez toute **fuite de cible**. Un gain doit être démontré expérimentalement.

Étape 5 — Interprétation et analyse d'erreurs

Analysez les variables importantes, les faux positifs et les faux négatifs. Proposez une utilisation opérationnelle raisonnable des probabilités produites.

Étape 6 — Soumission

Générez `submission.csv` à partir de `reservations_test.csv`, **sans modifier l'ordre des identifiants**.

4. Livrables — deadline 16h00

Règle de dépôt

Tout doit être poussé sur votre dépôt GitHub **avant 16h00**. Le dernier commit antérieur à la deadline fera foi.

1. Le fichier `submission.csv`

Le fichier doit contenir exactement trois colonnes :

- `reservation_id` — l'identifiant, dans l'ordre du fichier de test ;
- `probabilite_annulation` — la probabilité prédite, entre 0 et 1 ;
- `reservation_annulee` — la décision binaire issue de votre seuil.

```
1 submission = pd.DataFrame({  
2     "reservation_id": test_df["reservation_id"],  
3     "probabilite_annulation": model.predict_proba(X_test)[: , 1],  
4     "reservation_annulee": predictions  
5 })  
6 submission.to_csv("submission.csv", index=False)
```

2. Vidéo de présentation — 3 à 5 minutes

Présentez l'équipe, les constats majeurs de l'EDA, la baseline, le modèle final, les erreurs importantes et votre recommandation métier.

3. Code et notebook

Le notebook doit être structuré, commenté, reproductible et exécutable de bout en bout. **Fixez les graines aléatoires.**

4. Rapport `README.md`

Utilisez le canevas fourni. Chaque choix majeur doit être justifié par un résultat ou une observation.

5. Critères d'évaluation

Critère	Poids
Performance — F1-score sur la classe « annulation »	30 %
Méthodologie et validation	20 %
Feature engineering	15 %
Qualité du code	15 %
Analyse et README	10 %
Présentation (vidéo)	10 %
Total	100 %

6. Repères d'organisation de la journée

Le découpage ci-dessous est *indicatif* : il n'est pas évalué et chaque équipe reste libre de son organisation. Il sert de garde-fou pour éviter le piège classique du hackathon — passer sept heures sur l'exploration et trente minutes sur les livrables.

Créneau	Objectif
08h00 – 09h00	Prise en main des fichiers, cadrage de l'équipe, première lecture du dictionnaire de données
09h00 – 10h30	EDA, valeurs manquantes et atypiques, mise en place du protocole de validation temporelle
10h30 – 11h30	Baseline : régression logistique et premier score de référence
11h30 – 13h00	Feature engineering et itérations mesurées
13h00 – 14h30	Familles de modèles alternatives, réglage, choix du seuil de décision
14h30 – 15h15	Analyse d'erreurs, interprétation, recommandation métier
15h15 – 15h45	Génération de <code>submission.csv</code> et rédaction du README
15h45 – 16h00	Vérifications finales et dernier commit

Enregistrez la vidéo dès que le modèle final est figé : c'est le livrable le plus souvent sacrifié faute de temps, alors qu'il pèse autant que la qualité du code.

Avant de pousser votre dernier commit

- `submission.csv` contient 2 000 lignes et les trois colonnes demandées, dans l'ordre initial des identifiants.
- Le notebook s'exécute intégralement depuis un noyau vierge.
- Les graines aléatoires sont fixées et les scores annoncés dans le README sont reproductibles.
- Aucune information issue du jeu de test n'a servi à l'apprentissage des prétraitements.
- La vidéo est accessible (lien vérifié) et dure de 3 à 5 minutes.